

BÁO CÁO PROJECT CUỐI KỲ VIETNAMESE GRAPH RAG

Hệ thống Hỏi đáp Thông minh cho

Thương mại Điện tử Tiếng Việt

Môn học: Xử Lý Ngôn Ngữ Tự Nhiên (NLP)

Nhóm trưởng : Lê Phạm Hồng Hiên – 22110059

Thành viên 1 : Dương Bùi Phương Đình – 22110049

Thành viên 2 : Phạm Xuân Huyền – 22110076

Khoa : Toán – Tin học

Giảng viên : (Tên giảng viên)

Năm học : 2025 – 2026

Mục lục

1	Gii thiu	2
1.1	t vn	2
1.2	Mc tiêu d án	2
1.3	Phm vi	2
2	C s lý thuyt	3
2.1	Tin x lý vn bn ting Vit	3
2.2	Bag of Words và TF-IDF	3
2.3	Word Embeddings: Word2Vec và GloVe	3
2.4	Transformer và BERT/PhoBERT	3
2.5	Retrieval-Augmented Generation (RAG)	4
2.6	Knowledge Graph và Graph RAG	4
3	Dataset và Tin x lý d liu	4
3.1	Dataset s dng	4
3.2	Dataset chính: UIT-ViSFD	4
3.3	Dataset b sung: Shopee reviews	5
3.4	Phân tích nhân aspect	5
3.5	Pipeline tin x lý	5
4	Kin trúc h thng	6
4.1	Tng quan Pipeline	6
4.2	Bám sát chng trình môn hc (6 lecture)	7
4.3	Module 2: So sánh Embedding Methods	8
4.4	Module 3: Named Entity Recognition	9
4.5	Module 4: Knowledge Graph	10
4.6	Module 5: Retrieval vi Attention Re-ranking	10
5	Thc nghim	10
5.1	Môi trng thc nghim	10
5.2	Thí nghim 1: So sánh Embedding Methods	10
5.3	Thí nghim 2: Trích xut thc th (NER)	11
5.4	Thí nghim 2b: Phân loi aspect bng RNN (BiLSTM)	11
5.5	Thí nghim 3: Ablation chin lc Retrieval (không rò r metric)	11
5.6	Thí nghim 4: Demo End-to-End	11
6	Kt qu và Tho lun	12
7	Trin khai LLMOps	12
8	Phân công công vic	14
9	Kt lun	14
9.1	Tóm tt kt qu	14
9.2	Hn ch	14
9.3	Hng phát trin	15

1. Giới thiệu

1.1 Đặt vấn đề

Thương mại điện tử (TMĐT) tại Việt Nam đang phát triển bùng nổ với các nền tảng như **Shopee, Lazada, Tiki**. Mỗi ngày, hàng triệu đánh giá sản phẩm được đăng tải, tạo ra nguồn dữ liệu khổng lồ nhưng **phi cấu trúc**. Người mua hàng thường gặp khó khăn khi tìm kiếm thông tin cụ thể về sản phẩm từ hàng nghìn bình luận — ví dụ: “Camera iPhone 15 chụp đêm có tốt không?” hay “Pin Samsung S24 dùng được bao lâu?”.

Retrieval-Augmented Generation (RAG) là kiến trúc kết hợp giữa *truy xuất thông tin* (Information Retrieval) và *sinh văn bản* (Text Generation), cho phép mô hình ngôn ngữ trả lời dựa trên **nguồn tri thức cụ thể** — ở đây là các đánh giá sản phẩm thực tế.

Graph RAG mở rộng RAG truyền thống bằng cách bổ sung **đồ thị tri thức (Knowledge Graph)** — lưu trữ mối quan hệ giữa sản phẩm, thương hiệu, tính năng và cảm xúc người dùng — giúp truy xuất chính xác và có ngữ cảnh hơn.

1.2 Mục tiêu dự án

1. Xây dựng hệ thống **Vietnamese Graph RAG** cho bài toán hỏi đáp về sản phẩm TMĐT.
2. **So sánh** các phương pháp biểu diễn văn bản: TF-IDF, Word2Vec, GloVe, PhoBERT trên dữ liệu đánh giá sản phẩm.
3. **Trích xuất thực thể** (NER) từ đánh giá: tên sản phẩm, thương hiệu, tính năng, giá cả.
4. Xây dựng **Knowledge Graph** thể hiện quan hệ sản phẩm – thuộc tính – cảm xúc.
5. **Đánh giá hiệu quả** của Graph RAG so với RAG truyền thống trên domain TMĐT.

1.3 Phạm vi

- **Domain:** Thương mại điện tử — Đánh giá smartphone tiếng Việt
- **Dataset:** UIT-ViSFD (11,122 reviews; tập train 7,786 dùng cho thực nghiệm)
- **Mô hình:** TF-IDF, Word2Vec, GloVe-SVD, PhoBERT, Attention (late-interaction)
- **LLM:** OpenAI API (gpt-4o-mini) cho phần Generation

2. Cơ sở lý thuyết

2.1 Tiền xử lý văn bản tiếng Việt

Tiếng Việt là ngôn ngữ **đơn lập** (isolating language), trong đó ranh giới từ không được xác định bằng khoảng trắng. Ví dụ: “học sinh” là một từ ghép, không phải hai từ riêng biệt.

Công cụ sử dụng: Thư viện `underthesea` cung cấp chức năng tách từ (word segmentation) cho tiếng Việt:

Listing 1: Tách từ tiếng Việt

```
1 from underthesea import word_tokenize
2 text = "Truong_Dai_hoc_Khoa_hoc_Tu_nhien"
3 tokens = word_tokenize(text, format="text")
4 # "Truong_Dai_hoc Khoa_hoc Tu_nhien"
```

2.2 Bag of Words và TF-IDF

TF-IDF (Term Frequency – Inverse Document Frequency) đo lường mức độ quan trọng của một từ trong tài liệu so với toàn bộ tập tài liệu:

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \log \frac{N}{1 + \text{DF}(t)}$$

Trong dự án, TF-IDF được sử dụng làm **baseline** cho việc truy xuất đánh giá sản phẩm liên quan đến câu hỏi của người dùng.

2.3 Word Embeddings: Word2Vec và GloVe

Word2Vec (Mikolov et al., 2013) học biểu diễn từ dựa trên *ngữ cảnh lân cận*:

- **Skip-gram**: Dự đoán từ ngữ cảnh từ từ trung tâm
- **CBOW**: Dự đoán từ trung tâm từ ngữ cảnh

GloVe (Pennington et al., 2014) học embeddings dựa trên *ma trận đồng xuất hiện*, tối ưu hàm mất mát:

$$J = \sum_{i,j} f(X_{ij}) (w_i^T w_j + b_i + b_j - \log X_{ij})^2$$

2.4 Transformer và BERT/PhoBERT

Transformer (Vaswani et al., 2017) sử dụng cơ chế **Self-Attention** để xử lý song song toàn bộ chuỗi:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

PhoBERT (Nguyen & Nguyen, 2020) là mô hình BERT được pre-train trên 20GB dữ liệu tiếng Việt, đạt state-of-the-art trên nhiều tác vụ NLP tiếng Việt.

2.5 Retrieval-Augmented Generation (RAG)

RAG kết hợp hai thành phần:

1. **Retriever**: Tìm kiếm tài liệu liên quan từ knowledge base
2. **Generator**: Sinh câu trả lời dựa trên tài liệu đã tìm được

2.6 Knowledge Graph và Graph RAG

Knowledge Graph lưu trữ thông tin dưới dạng **bộ ba** (triple): (h, r, t) — head entity, relation, tail entity. Ví dụ trong TMDT:

(iPhone_15, thuộc_thương_hiệu, Apple)
 (iPhone_15, có_tính_năng, Camera_48MP)
 (Camera_48MP, được_đánh_giá, Tích_cực_85%)

Graph RAG bổ sung bước **graph traversal** vào pipeline RAG, cho phép truy xuất thông tin có cấu trúc — ví dụ khi hỏi về “camera iPhone 15”, hệ thống có thể duyệt graph để tìm tất cả đánh giá liên quan đến tính năng camera.

3. Dataset và Tiền xử lý dữ liệu

3.1 Dataset sử dụng

Bảng 1: Tổng hợp các dataset sử dụng trong dự án

Dataset	Tác vụ	Kích thước	Nguồn
UIT-ViSFD	Aspect-Based Sentiment	11,122 comments	Shopee
Shopee reviews	Review đa sản phẩm	3,154 reviews	GitHub (nhtlongcs)
PhoNER_COVID19	NER (tham khảo)	domain COVID	HuggingFace

*Ghi chú: PhoNER_COVID19 thuộc domain COVID nên không phù hợp gán nhãn thực thể sản phẩm; chỉ tải về tham khảo. Việc trích xuất thương hiệu dùng NER tổng quát (*underthesea*) kết hợp gazetteer.*

3.2 Dataset chính: UIT-ViSFD

UIT-ViSFD (Vietnamese Smartphone Feedback Dataset) là bộ dữ liệu đánh giá smartphone từ sàn TMDT Việt Nam, được gán nhãn bởi con người với:

- **10 aspect categories**: SCREEN, CAMERA, BATTERY, PERFORMANCE, STORAGE, DESIGN, PRICE, GENERAL, FEATURES, SER&ACC (Service & Accessories)
- **3 sentiment polarities**: Positive, Negative, Neutral
- **11,122 comments** với annotation ở mức aspect-level

Ví dụ dữ liệu:

“Camera chụp đêm rất nét, pin dùng được 2 ngày, nhưng giá hơi cao so với cấu hình.”

→ CAMERA: Positive, BATTERY: Positive, PRICE: Negative

Listing 2: Tải và khám phá dataset UIT-ViSFD

```

1 import pandas as pd
2 # Dataset có thể tải từ GitHub UIT-NLP
3 # hoặc từ HuggingFace: SEACrowd/uit_visfd
4 df = pd.read_csv("data/raw/UIT-ViSFD_train.csv")
5 print(f"Total comments: {len(df)}")
6 print(f"Aspects: {df['aspect'].unique()}")
7 print(f"Sentiments: {df['polarity'].value_counts()}")

```

3.3 Dataset bổ sung: Shopee reviews

Để mở rộng ngoài domain smartphone, chúng tôi bổ sung **3.154 review Shopee đa sản phẩm** (26 sản phẩm, 24 shop) gồm các trường `comment`, `product_name`, `shop_name`, `rating_star`. Bộ này **không có nhãn aspect**, nên được dùng cho hai mục đích: (1) mở rộng corpus truy xuất (Graph RAG trả lời được câu hỏi đa sản phẩm), và (2) cung cấp các thực thể `shop/product` cho Knowledge Graph. Aspect cho review Shopee được **dự đoán bằng mô hình BiLSTM** (Mục 5.4) thay vì nhãn vàng.

3.4 Phân tích nhãn aspect


Nhãn của UIT-ViSFD có dạng chuỗi `{ASPECT#Sentiment}` ngăn cách bởi dấu `;`. Một điểm cần lưu ý: aspect **SER&ACC** chứa ký tự `&`, nên biểu thức chính quy ngây thơ `\{(\w+)\#(\w+)\}` sẽ **bỏ sót** aspect này (1.995 lần trong tập train — aspect phổ biến thứ 7). Chúng tôi sửa thành `\{([\w&])+(\w+)\}` để giữ đủ 10 aspect.

3.5 Pipeline tiền xử lý


1. **Cleaning**: lowercase, loại URL, ký tự đặc biệt, chữ số, chuẩn hóa khoảng trắng.
2. **Word Segmentation**: tách từ tiếng Việt bằng `underthesea`.
3. **Stopword Removal**: loại từ dừng (cho TF-IDF/Word2Vec/GloVe).
4. **Lưu ý nhất quán**: PhoBERT dùng văn bản **đã tách từ nhưng giữ dấu/số** (không loại stopwords), đúng với pipeline khuyến nghị của PhoBERT; các phương pháp đếm dùng bản đã làm sạch.

4. Kiến trúc hệ thống

4.1 Tổng quan Pipeline



Hình 1: Kiến trúc tổng quan hệ thống Vietnamese Graph RAG gồm 6 module chính



Hình 2: Sequence Diagram: Luồng xử lý khi người dùng đặt câu hỏi

Hệ thống gồm 6 module chính:

1. **Module 1 – Tiền xử lý:** Xử lý văn bản tiếng Việt (tách từ, loại stopwords)
2. **Module 2 – Embedding:** So sánh TF-IDF, Word2Vec, GloVe, PhoBERT
3. **Module 3 – NER:** Trích xuất thực thể bằng underthesea + gazetteer
4. **Module 4 – Knowledge Graph:** Xây dựng đồ thị tri thức (NetworkX)
5. **Module 5 – Retrieval:** Embedding + Graph boost + Attention (MaxSim) re-ranking
6. **Module 6 – Generation:** Tích hợp LLM API (OpenAI)

4.2 Bám sát chương trình môn học (6 lecture)

Các thành phần của hệ thống ánh xạ trực tiếp tới 6 bài giảng của môn:

Lecture	Nội dung	Áp dụng trong project
Lec02 – Word Representation	one-hot, TF-IDF, Word2Vec, GloVe	So sánh TF-IDF / Word2Vec / GloVe-SVD
Lec03 – Subword Models	BPE, subword	Tokenize BPE (PhoBERT) cho từ hiếm/OOV
Lec04 – Compositional Semantics	Document→Sentence→Phrase→Word	Knowledge Graph: brand→aspect→sentiment, shop→product
Lec05 – Recurrent Neural Networks	RNN/LSTM, dữ liệu tuần tự	BiLSTM phân loại đa nhãn aspect (micro-F1)
Lec06 – Attention & Transformer	attention, encoder–decoder	PhoBERT + tái xếp hạng MaxSim (late-interaction)


Bảng 2: Ánh xạ thành phần hệ thống $\leftrightarrow$ 6 lecture của môn.

4.3 Module 2: So sánh Embedding Methods

Đây là module quan trọng nhất, thể hiện kiến thức NLP cốt lõi. Chúng tôi so sánh 4 phương pháp biểu diễn văn bản:

Bảng 3: So sánh 4 phương pháp Embedding

Phương pháp	Loại	Đặc điểm	Lecture
TF-IDF	Sparse, thống kê	Baseline, không capture ngữ nghĩa	Lec02
Word2Vec	Dense, predictive	Skip-gram/CBOW, ngữ cảnh cục bộ	Lec02
GloVe	Dense, count-based	Co-occurrence matrix, ngữ nghĩa toàn cục	Lec02
PhoBERT	Dense, contextual	Transformer, tiếng Việt, SOTA	Lec06



Hình 3: So sánh hiệu quả Retrieval giữa 4 phương pháp Embedding (Precision@k & MRR)

Lưu ý về độ đo: không dùng “trung bình cosine similarity” để so sánh, vì độ lớn cosine **không so sánh được** giữa các không gian embedding khác nhau (TF-IDF thừa cho giá trị thấp hơn PhoBERT dầy). Thay vào đó dùng **Precision@k** và **MRR** với ground-truth là nhãn aspect (xem Mục 5.2).

Lưu ý về “GloVe”: do hạn chế tài nguyên, chúng tôi dùng **xấp xỉ kiểu GloVe** — SVD trên ma trận đồng xuất hiện ở mức tài liệu (gần với LSA), không phải GloVe của sổ ngữ cảnh gốc.

4.4 Module 3: Named Entity Recognition

NER tổng quát của *underthesea* (nhãn PER/LOC/ORG) bắt tốt các thực thể **thương hiệu** và **cửa hàng** (vd. *Apple*, *Thế Giới Di Động*). Thực thể đặc thù e-commerce (dòng máy) không nằm trong tập nhãn tổng quát nên được bổ sung bằng **gazetteer thương hiệu**. Các thực thể thương hiệu này được đưa vào Knowledge Graph làm node **brand**. (PhoNER_COVID19 không dùng vì khác domain.)

4.5 Module 4: Knowledge Graph

*Copy `fig_knowledge_graph.png` từ output notebook Part 2 vào
`report/figures/knowledge_graph.png`*

Hình 4: Knowledge Graph: $\text{brand} \rightarrow \text{aspect} \rightarrow \text{aspect\#sentiment}$, trọng số cạnh = số review.

Đồ thị có hướng (NetworkX) gồm 3 loại node: **brand**, **aspect** (10 aspect gồm SER&ACC) và **aspect#sentiment**. Cạnh $\text{brand} \rightarrow \text{aspect}$ và $\text{aspect} \rightarrow \text{sentiment}$ mang trọng số là số review, cho phép truy vấn phân bố cảm xúc theo từng khía cạnh.

4.6 Module 5: Retrieval với Attention Re-ranking

Pipeline truy xuất 2 tầng: (1) **bi-encoder** PhoBERT (mean-pooling) tính cosine để lấy Top-50 candidate; (2) **tái xếp hạng late-interaction (MaxSim, kiểu ColBERT)** — với mỗi token của truy vấn, lấy cosine lớn nhất so với các token của tài liệu rồi tính trung bình. Đây là cơ chế **attention** (tích vô hướng có chuẩn hoá giữa token query và token doc), **không tham số ngẫu nhiên và không cần huấn luyện**. Điểm cuối kết hợp: bi-encoder, MaxSim, và một **graph boost** dựa trên aspect quan sát được trong nội dung review.

5. Thực nghiệm

5.1 Môi trường thực nghiệm

Bảng 4: Cấu hình môi trường thực nghiệm

Thành phần	Chi tiết
Platform	Google Colab (T4 GPU)
Python	3.10+
PyTorch	2.x
Transformers	5.x
Các thư viện khác	underthesea, gensim, networkx, faiss-cpu

5.2 Thí nghiệm 1: So sánh Embedding Methods

Thiết lập: 9 truy vấn (mỗi truy vấn nhắm 1 aspect). Một review được coi là *liên quan* nếu nhãn vàng của nó chứa aspect đó. Báo cáo Precision@5, Precision@10, MRR (trung bình trên các truy vấn). Cùng một phán quyết liên quan áp dụng cho cả 4 phương pháp $\Rightarrow$ công bằng.

Bảng 5: Precision@k & MRR theo phương pháp embedding (điền số từ *results_part1.json* / bảng LaTeX in ra ở notebook Part 1)

Phương pháp	P@5	P@10	MRR
TF-IDF	...	...	...
Word2Vec	...	...	...
GloVe-SVD	...	...	...
PhoBERT	...	...	...

5.3 Thí nghiệm 2: Trích xuất thực thể (NER)

Thống kê số thực thể theo loại (PER/LOC/ORG + BRAND từ gazetteer) trên 800 review mẫu được in ở notebook Part 1 (*results_part1.json*). Phân tích định tính: NER tổng quát nhận diện tốt thương hiệu (ORG) và địa điểm cửa hàng (LOC); gazetteer bổ sung node brand cho KG.

5.4 Thí nghiệm 2b: Phân loại aspect bằng RNN (BiLSTM)

Hiện thực **Lec05 (Recurrent Neural Networks)**: một **BiLSTM** (embedding 100, hidden 128, hai chiều) phân loại **đa nhãn** 10 aspect từ review, huấn luyện trên tập train UIT-ViSFD và đánh giá **micro-F1** trên tập dev. Mô hình sau khi train được **lưu lại** (*artifacts/aspect_clf.pt*) và **triển khai** trong hệ thống (xem Mục 7): dùng để gán aspect cho review Shopee (không có nhãn) nhằm làm giàu Knowledge Graph, và phục vụ trực tiếp qua API POST /classify.

Micro-F1 (dev): [điền từ results_part1.json / artifacts/metrics.json]

5.5 Thí nghiệm 3: Ablation chiến lược Retrieval (không rõ rí metric)

Thiết lập: trên cùng tập Top-50 candidate, thay đổi trọng số 3 thành phần. **Quan trọng**: graph boost dựa trên aspect *quan sát trong nội dung review* (tín hiệu khả dụng lúc suy luận), còn phán quyết liên quan dùng *nhãn vàng* — hai nguồn độc lập nên không có rò rỉ.

Bảng 6: Ablation: đóng góp của Attention và Graph (điền từ *results_part2.json*)

Cấu hình	P@5	P@10	MRR
Bi-encoder (PhoBERT)	...	...	...
+ Attention rerank (MaxSim)	...	...	...
+ Graph (Graph RAG)	...	...	...

5.6 Thí nghiệm 4: Demo End-to-End

Ba câu hỏi mẫu (camera, pin, dịch vụ/bảo hành) chạy qua pipeline đầy đủ Retrieve → Graph context → OpenAI (gpt-4o-mini). Câu trả lời mẫu và thống kê KG kèm theo được in ở notebook Part 2.

6. Kết quả và Thảo luận

Embedding: kỳ vọng PhoBERT đạt P@k/MRR cao nhất nhờ biểu diễn ngữ cảnh, TF-IDF là baseline; Word2Vec/GloVe-SVD ở giữa. Số liệu cụ thể điền từ Thí nghiệm 1.

Retrieval: ablation cho thấy đóng góp riêng của (i) tái xếp hạng attention MaxSim và (ii) graph boost. Vì đánh giá không còn rõ rĩ metric (boost từ nội dung, chấm điểm bằng nhãn vàng), chênh lệch quan sát được phản ánh cải thiện thực — không còn là kết quả “được sắp đặt” như cách boost trực tiếp theo nhãn vàng.

Hạn chế quan sát được: graph boost chỉ kích hoạt khi câu hỏi khớp được aspect tiếng Việt; với câu hỏi mơ hồ (không nêu rõ khía cạnh), đóng góp của graph giảm.

7. Triển khai LLMOps

Ngoài notebook khám phá, hệ thống được đóng gói thành một **pipeline LLMOps production-lite** (package `src/vngraphrag`) tách hai pha:

- **Offline (build):** encode corpus bằng PhoBERT, dựng index + Knowledge Graph, lưu thành *artifacts có version* (`doc_vectors.npy`, `records.json`, `manifest.json`, `kg.pkl`). Manifest gán mã version = hash(model, số bản ghi) để chặn việc nạp nhầm index cũ.
- **Online (serve):** nạp lại artifacts; mỗi truy vấn đi qua `retrieve` → `graph context` → `generate` và được ghi log đo đạc.

Thành phần LL-MOps	Hiện thực
Cấu hình & secret	<code>config.yaml</code> + biến môi trường (<code>OPENAI_API_KEY</code> chỉ qua env)
Versioning artifact	<code>DocumentIndex</code> manifest; tự rebuild khi model/dữ liệu đổi
Train → deploy model	BiLSTM train ở notebook → <code>aspect_clf.pt</code> → nạp ở <code>core/aspect_clf.py</code> → phục vụ qua <code>POST /classify</code> ; đồng thời gán aspect cho review Shopee để làm giàu KG
Serving API	FastAPI: <code>/query</code> , <code>/classify</code> , <code>/feedback</code> , <code>/health</code>
Giao diện + feedback loop	Gradio UI, nút thích/không-thích → <code>logs/feedback.jsonl</code>
Observability	mỗi truy vấn log latency + token + chi phí USD vào <code>logs/queries.jsonl</code>
Đánh giá + regression gate	<code>evaluate.py</code> : Precision@k/MRR (retrieval) và micro-F1 (BiLSTM); CI fail nếu tụt dưới ngưỡng
Đóng gói + CI	<code>Dockerfile</code> + GitHub Actions (lint + test)

Bảng 7: Các thành phần LLMOps của hệ thống.

Điểm đáng chú ý là **vòng lặp train → deploy** khép kín: mô hình BiLSTM (Lec05) huấn luyện trong notebook được lưu thành artifact, nạp lại bởi package phục vụ, và sử dụng thực sự ở hai nơi — gán aspect cho dữ liệu Shopee chưa nhãn (làm giàu Knowledge Graph) và phục vụ trực tiếp qua endpoint `/classify`.

8. Phân công công việc

Bảng 8: Phân công công việc nhóm

Lê Hiền 22110059	Phạm Hồng Đình 22110049	Dương Bùi Đình 22110049	Phạm Xuân Huyền 22110076
Kiến trúc tổng thể	Tiền xử lý dữ liệu (Lec01)	Word Representation (Lec02)	
Module 5: Attention/MaxSim re-ranking (Lec06)	Module 1: Preprocessing	Module 2: So sánh embedding (P@k/MRR)	
Module 6: RAG Pipeline + OpenAI	Module 3: NER + gazetteer	Subword/BPE (Lec03)	
LLMOps: package, FastAPI, CI/Docker, observability	RNN/BiLSTM (Lec05): train + deploy aspect classifier	Module 4: Knowledge Graph + Gradio UI	
Tích hợp & testing (make check)	Tích hợp dataset Shopee	Evaluation & metrics (gate)	
Báo cáo & trình bày	Báo cáo (Data, NER, RNN)	Báo cáo (Embedding, KG)	

9. Kết luận

9.1 Tóm tắt kết quả

Dự án xây dựng pipeline Graph RAG hoàn chỉnh cho review smartphone tiếng Việt: tiền xử lý + tách từ, so sánh 4 phương pháp embedding bằng độ đo truy xuất đúng (P@k, MRR), NER thương hiệu nối vào Knowledge Graph, tái xếp hạng bằng attention late-interaction, và sinh câu trả lời bằng OpenAI với ngữ cảnh từ đồ thị.

9.2 Hạn chế

- “GloVe” chỉ là xấp xỉ SVD trên đồng xuất hiện mức tài liệu, chưa phải GloVe gốc.
- Tái xếp hạng MaxSim không huấn luyện; chưa fine-tune trên dữ liệu cặp truy vấn–tài liệu.
- Ánh xạ câu hỏi → aspect dựa trên từ khóa thủ công, chưa bao phủ mọi cách diễn đạt.

- NER dùng mô hình tổng quát + gazetteer, chưa có NER huấn luyện riêng cho domain điện thoại.

9.3 Hướng phát triển

- Fine-tune cross-encoder PhoBERT cho re-ranking với nhãn liên quan tách biệt train/test.
- Mở rộng KG với quan hệ sản phẩm–linh kiện và liên kết thực thể (entity linking).
- Phân loại aspect câu hỏi bằng mô hình thay cho từ khóa; đánh giá thêm trên tập dev/test.

Tài liệu

- [1] Vaswani, A., et al. (2017). “Attention Is All You Need.” *NeurIPS 2017*.
- [2] Devlin, J., et al. (2019). “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding.” *NAACL 2019*.
- [3] Nguyen, D.Q. & Nguyen, A.T. (2020). “PhoBERT: Pre-trained language models for Vietnamese.” *Findings of EMNLP 2020*.
- [4] Nguyen, K., et al. (2020). “A Vietnamese Dataset for Evaluating Machine Reading Comprehension.” *COLING 2020*.
- [5] Mikolov, T., et al. (2013). “Efficient Estimation of Word Representations in Vector Space.” *ICLR 2013*.
- [6] Pennington, J., Socher, R., & Manning, C. (2014). “GloVe: Global Vectors for Word Representation.” *EMNLP 2014*.
- [7] Lewis, P., et al. (2020). “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks.” *NeurIPS 2020*.
- [8] Microsoft Research. (2024). “From Local to Global: A Graph RAG Approach to Query-Focused Summarization.”